

Análisis Exhaustivo del Empirical Mode Decomposition (EMD) y su Aplicación en Señales de Electrocardiograma (ECG)

Fundamentos Conceptuales y Algorítmicos del Empirical Mode Decomposition

El Empirical Mode Decomposition (EMD), desarrollado por Norden E. Huang y colaboradores en 1998, representa un avance paradigmático en el procesamiento de señales, especialmente para aquellos dominios donde las suposiciones de linealidad y estacionariedad no se cumplen [14](#) [17](#). Su introducción fue un reconocimiento explícito de que muchas señales naturales, incluyendo las biomédicas como el electrocardiograma (ECG), son inherentemente no lineales y no estacionarias [12](#) [15](#). La filosofía central del EMD reside en su naturaleza completamente adaptativa y basada en los datos; a diferencia de métodos tradicionales como la Transformada de Fourier (FT) o la Transformada Wavelet (WT), que dependen de bases de funciones predefinidas, el EMD genera sus propias "bases" directamente a partir de la estructura interna de la señal que se está analizando [8](#) [11](#) [12](#). Esta propiedad fundamental es la clave de su eficacia en el análisis de señales complejas. La FT, por ejemplo, asume que la señal es periódica e infinita en el tiempo, una hipótesis que viola sistemáticamente las características de las señales reales y que lleva a problemas de resolución frecuencia-tiempo y a la aparición de armónicos artificiales en señales no sinusoidales [15](#) [19](#). De manera similar, la WT, aunque más flexible, todavía depende de una función madre (wavelet) definida a priori, cuya elección puede no ser óptima para capturar la dinámica local variante en el tiempo de una señal como el ECG [21](#). El EMD, en cambio, elimina esta dependencia externa, haciendo posible una representación intrínseca y localizada tanto en el tiempo como en la frecuencia, lo que lo convierte en una herramienta excepcionalmente adecuada para el análisis de señales biológicas [12](#).

El producto fundamental de una descomposición EMD es un conjunto finito de componentes denominados Intrinsic Mode Functions (IMFs), junto con un residuo final [1](#) [17](#). Cada IMF es un componente oscilatorio monocomponente, lo que

significa que posee una única escala de tiempo-frecuencia variable en el tiempo ³⁴. Matemáticamente, una función debe satisfacer dos condiciones estrictas para ser considerada una IMF válida. La primera condición establece que el número total de máximos locales y mínimos locales debe ser igual o diferir en a lo sumo uno ^{3 11 17 20 24}. La segunda y quizás más crucial condición requiere que, en cualquier punto de la señal, el promedio de la envolvente superior (la curva que conecta todos los máximos locales) y la envolvente inferior (la curva que conecta todos los mínimos locales) sea cero ^{3 11 14 24}. Este segundo criterio garantiza la simetría local de la IMF alrededor del eje de tiempo, asegurando que no contenga "ondas de montaje" (riding waves) o tendencias residuales dentro de su propio ciclo, lo que la hace ideal para representar oscilaciones bien comportadas con amplitud y frecuencia instantáneas bien definidas ^{17 24}. Los IMFs resultantes de una descomposición se ordenan desde el de mayor frecuencia (el más rápido) hasta el de menor frecuencia (el más lento), y la suma de todos ellos, junto con el residuo final, reconstruye exactamente la señal original ^{17 60}. El residuo final, por otro lado, representa la tendencia global o la media de la señal a largo plazo ^{16 17}.

El mecanismo mediante el cual se obtienen estos IMFs es un proceso iterativo conocido como "tamizado" (sifting process). Este algoritmo, aunque conceptualmente simple, es computacionalmente intensivo. Comienza identificando todos los puntos de inflexión (máximos y mínimos locales) de la señal de entrada $x(t)$ ^[1,3]. A continuación, se interpola la envolvente superior y la inferior utilizando interpolación por splines cúbicos, una técnica robusta que crea curvas suaves que pasan a través de todos los puntos extremos ^{1 3 11}. Se calcula entonces la media de estas dos envolventes, denotada como $m(t)$ ^[1,36]. La siguiente etapa consiste en restar esta envolvente media de la señal original para obtener un nuevo componente, $h(t) = x(t) - m(t)$ ^[3,20]. A continuación, se verifica si este nuevo componente $h(t)$ cumple con los dos criterios de IMF mencionados anteriormente. Si no los cumple, se toma $h(t)$ como la nueva señal de entrada ($x(t)$) y se repiten los pasos de interpolación de envolventes y resta de su media ^{3 20}. Este ciclo iterativo continúa hasta que el resultado final satisface las condiciones de IMF. Una vez validado, este componente se designa como el primer IMF, $c_1(t)$. El proceso se completa restando este IMF de la señal original para obtener un nuevo residuo, $r_1(t) = x(t) - c_1(t)$ ^[3,20]. Luego, se repite todo el proceso de tamizado sobre este nuevo residuo para extraer el segundo IMF, $c_2(t)$, y así sucesivamente, hasta que el residuo final es tan simple que ya no tiene más puntos de inflexión (es decir, es monótonico) o alcanza un umbral de energía muy bajo, momento en el cual se detiene la descomposición ^{1 3 20}. La fórmula

general para la reconstrucción de la señal es, por lo tanto, $x(t) = \sum_{i=1}^n c_i(t) + r_n(t)$, donde $c_i(t)$ son los IMFs y $r_n(t)$ es el residuo final [1](#) [3](#). Este proceso garantiza que la información contenida en la señal original se distribuya entre los IMFs, cada uno capturando una parte específica de la dinámica temporal-frecuencial de la señal.

Variantes Avanzadas y Mitigación de Limitaciones del EMD Original

A pesar de su poderosa capacidad adaptativa, el algoritmo EMD original presenta varias limitaciones inherentes que han motivado el desarrollo de variantes más robustas y estables. La limitación más significativa y recurrentemente citada es el fenómeno conocido como "modo mezclado" (mode mixing) [16](#) [22](#). Este problema ocurre cuando una sola IMF contiene componentes de muy diferente escala de tiempo (por ejemplo, una alta frecuencia y una baja frecuencia) o, inversamente, cuando un componente de escala similar se encuentra disperso en múltiples IMFs distintos [16](#) [36](#). El modo mezclado puede hacer que la interpretación de los resultados sea ambigua y difícil, y puede degradar el rendimiento en aplicaciones prácticas como la detección de picos o la clasificación de arritmias. Otra debilidad importante es el efecto de borde (end effects), que surge debido a la interpolación por splines cúbicos utilizada para generar las envolventes [16](#) [36](#). En los bordes de la señal, donde hay menos puntos de referencia, la interpolación puede divergir, introduciendo distorsiones significativas en los primeros y últimos IMFs generados, lo que compromete la integridad de la descomposición en esos segmentos críticos [16](#). Además, el EMD carece de una base matemática rigurosa; los IMFs resultantes no son ortogonales entre sí ni conservan necesariamente la energía total de la señal, lo que contrasta con las propiedades teóricas sólidas de transformadas como la Wavelet [36](#). Estas limitaciones han impulsado la investigación hacia metodologías mejoradas que buscan mitigar estos problemas.

Para abordar el problema del modo mezclado, se desarrollaron variantes basadas en el ensamblaje de ruido, siendo la más prominente la Ensemble Empirical Mode Decomposition (EEMD) [1](#) [3](#). El principio detrás del EEMD es añadir repetidamente series de ruido blanco gaussiano de amplitud finita a la señal original antes de cada descomposición EMD [3](#). Cada realización de ruido blanco se introduce en un ensayo independiente, y luego se realiza una EMD en cada versión ruidosa de la señal [1](#). El resultado final para cada IMF es el promedio de los correspondientes

IMFs obtenidos en todos los ensayos ¹ ³ . El efecto del ruido añadido es "desplegar" los modos de la señal en diferentes regiones del espacio de frecuencia, de modo que, al promediar sobre un gran número de ensayos, el ruido se cancela aproximadamente mientras que las verdaderas componentes de la señal se consolidan en IMFs coherentes ¹ . Esto mitiga drásticamente el modo mezclado, aunque introduce un pequeño nivel de ruido residual en los IMFs finales ³ .

Una mejora aún más sofisticada sobre el EEMD es la Complete Ensemble Empirical Mode Decomposition with Adaptive Noise (CEEMDAN) ³ ⁹ . CEEMDAN aborda una de las debilidades del EEMD, que es la contaminación residual del ruido en los IMFs, y también reduce el número de IMFs necesarios para una descomposición precisa ⁹ . El algoritmo de CEEMDAN es más complejo pero produce resultados más limpios y estables. Consiste en añadir pares de ruidos blancos positivos y negativos en cada etapa del proceso de tamizado, lo que permite estimar de manera más precisa el residuo verdadero en cada iteración ³ . Esta adaptividad en la adición del ruido en cada etapa ayuda a separar las diferentes escalas de la señal de forma más clara, resultando en IMFs con mayor contenido informativo y menos contaminación por ruido ⁹ ⁶² . CEEMDAN ha sido destacado en la literatura reciente como una herramienta particularmente adecuada para el procesamiento de señales biomédicas, ofreciendo una alternativa robusta a los métodos de filtrado convencionales ⁶² . Otros enfoques alternativos, como la Variational Mode Decomposition (VMD), abordan el problema desde una perspectiva completamente diferente, formulando la descomposición como un problema de optimización variacional en el dominio de la frecuencia, lo que resulta en modos estrechos de banda y sin solapamiento, evitando así el modo mezclado de forma inherente ²² . Sin embargo, para el contexto de EMD, CEEMDAN representa la evolución más directa y comúnmente adoptada de la técnica original para mejorar su fiabilidad y precisión en aplicaciones críticas como el análisis de ECG.

Característica	Empirical Mode Decomposition (EMD)	Ensemble EMD (EEMD)	Complete Ensemble EMD with Adaptive Noise (CEEMDAN)
Principio Fundamental	Descomposición adaptativa basada en los datos de la señal 8 .	Añade ruido blanco finito en múltiples ensayos y promedia los resultados para mitigar el modo mezclado 1 3 .	Añade ruido adaptativo en cada etapa del proceso de tamizado para una separación de modos más precisa 3 9 .
Solución Principal	Genera IMFs basados en la propia señal.	Reduce el modo mezclado y el modo mezclado cruzado 1 2 .	Mejora la calidad de los IMFs, reduce el modo mezclado y minimiza la contaminación por ruido residual 9 63 .
Ventaja Clave	Totalmente adaptativo, no requiere una base predefinida 11 .	Mayor robustez frente a señales con fluctuaciones rápidas de energía 5 .	Producción de IMFs más estables y físicamente interpretables; considerado una herramienta adecuada para señales biomédicas 62 .
Desventaja Principal	Propenso al modo mezclado y a los efectos de borde 16 36 .	Introduce un pequeño nivel de ruido residual en los IMFs finales 3 .	Algoritmo más complejo que EMD y EEMD, lo que puede aumentar la carga computacional 9 .
Relevancia en ECG	Base para métodos más avanzados; susceptible a errores en presencia de fuerte ruido 50 .	Utilizado para extracción de entropía de HRV y reducción de ruido 5 7 .	Mencionado como una herramienta robusta para señales biomédicas; utilizado en QRS/P-wave detection y clasificación de arritmias 9 32 62 .

Aplicaciones Clave del EMD en el Procesamiento de Señales ECG

La aplicación del Empirical Mode Decomposition en el análisis de señales de electrocardiograma (ECG) es particularmente potente debido a la naturaleza inherentemente no lineal y no estacionaria de la actividad eléctrica cardíaca [12](#) [15](#). El ECG es una señal compuesta por una serie de ondas (P, QRS, T) con morfologías y duraciones variables, además de estar constantemente afectada por diversos tipos de ruido y artefactos fisiológicos [49](#). Las técnicas de filtrado tradicionales pueden ser insuficientes cuando el espectro de frecuencia del ruido se solapa con el de la señal cardíaca relevante [48](#) [49](#). El EMD, por su parte, ofrece un enfoque de preprocesamiento inteligente y adaptativo. La estrategia fundamental radica en la observación empírica de que diferentes tipos de interferencia tienden a concentrarse predominantemente en ciertos IMFs durante la descomposición [27](#) [50](#). Por ejemplo, el interferencia de línea de potencia (PLI), que suele manifestarse como una señal sinusoidal a 50 Hz o 60 Hz, típicamente reside en el primer IMF (IMF1) [27](#) [49](#) [50](#). Del mismo modo, los artefactos musculares electromiográficos (EMG), que tienen un ancho de banda que puede solaparse con el del QRS, se

encuentran a menudo en los IMFs de alta frecuencia intermedios, como IMF2 hasta IMF5 [2](#) [27](#) [50](#) . Por otro lado, el "baseline wander" (BW), una deriva de baja frecuencia (<1 Hz) causada principalmente por movimientos respiratorios, se localiza en los IMFs de baja frecuencia más altos y en el residuo final [8](#) [49](#) [50](#) .

Esta partición natural de los componentes de la señal permite un proceso de denoising muy efectivo. El procedimiento consiste en realizar una descomposición EMD (preferiblemente una variante robusta como CEEMDAN para mayor fiabilidad [9](#)) sobre la señal ECG contaminada. Una vez obtenidos los IMFs, el analista puede visualizarlos para identificar aquellos que contienen predominantemente ruido. Por ejemplo, para eliminar el PLI, simplemente se descarta el IMF1. Para corregir el BW, se omiten los últimos IMFs y el residuo. Finalmente, para atenuar los artefactos musculares, se eliminan los IMFs intermedios identificados como ruidosos. La señal de ECG limpia se reconstruye sumando los IMFs restantes [26](#) [60](#) . La eficacia de estos métodos híbridos, que combinan EMD con otros filtros como wavelets o mean filters, ha demostrado ser superior a la de los métodos individuales, logrando mejoras significativas en métricas como el SNR (Signal-to-Noise Ratio), una reducción en el MSE (Error Cuadrático Medio) y una disminución en el PRD (Percent Root Mean Square Difference) [2](#) [43](#) [51](#) . Un estudio que combinaba EMD con Wavelet Packet (WP) y EMD logró una mejora media del SNR de 5.74 dB en el dataset CPSC2018 [2](#) , mientras que un método híbrido EMD-NLM (Non-Local Means) logró una mejora de SNR superior a 8 dB en el MIT-BIH database [51](#) . Sin embargo, la eficacia del EMD como método de denoising depende críticamente de la correcta identificación de los IMFs ruidosos, y bajo niveles de ruido extremadamente altos, el modo mezclado puede dificultar esta tarea, llevando a outliers con un PRD muy alto ($>100\%$) [27](#) .

Más allá de la simple eliminación de ruido, el EMD sirve como una poderosa herramienta de separación de fuentes adaptativa. Permite aislar morfologías específicas de la señal cardíaca que residen en diferentes bandas de frecuencia-tiempo, incluso cuando están fuertemente mezcladas en la señal original. Esto abre la puerta a la detección de arritmias y la extracción de características diagnósticas con una precisión que puede superar a los métodos tradicionales. Varios estudios han demostrado la viabilidad de detectar complejos QRS y ondas fiduciales (como la onda P) utilizando únicamente la información contenida en los IMFs. Un enfoque innovador basado en CEEMDAN seleccionó los IMFs 2 a 5 para reconstruir una señal de alta calidad que facilitaba la detección del complejo QRS, logrando una sensibilidad del 99.96% y un valor predictivo positivo (PPV) del 99.9% en el MIT-BIH Arrhythmia Database [9](#) . Otro método propuso una reconstrucción

especializada para mejorar la prominencia de los picos R, multiplicando la suma de los primeros cuatro IMFs por el producto de los tres primeros IMFs, seguido de una detección de picos basada en umbrales [40](#). Este enfoque de reconstrucción selectiva es crucial, ya que permite enfocar el análisis en las características de interés, atenuando el ruido y las componentes no relevantes. La capacidad del EMD para aislar componentes permitió el desarrollo de un algoritmo para diferenciar episodios de fibrilación ventricular (VF) de taquicardia ventricular (VT). El algoritmo se basó en la observación de que, en VF, la suma de los primeros dos IMFs muestra una alta correlación con la señal original, mientras que esto no ocurre en VT, permitiendo una discriminación con una especificidad del 99.32% [58](#). Estas aplicaciones demuestran que el EMD no es solo un filtro, sino un analizador de señales que revela la estructura subyacente de la actividad cardíaca, habilitando diagnósticos más precisos y automatizados.

Extracción de Características Diagnósticas y Detección de Arritmias con EMD

La verdadera fortaleza del Empirical Mode Decomposition en el ámbito biomédico reside en su capacidad para actuar como un extractor de características robusto, permitiendo la creación de nuevos indicadores diagnósticos y la implementación de sistemas de clasificación de arritmias altamente precisos. Al descomponer la señal ECG en un conjunto de IMFs, cada uno representando una escala de tiempo-frecuencia específica, el EMD proporciona un dominio de características mucho más rico y sensible que el dominio de tiempo o frecuencia único de las transformadas tradicionales [18](#). Cada IMF puede ser tratado como una señal individual, y diversas estadísticas y métricas pueden calcularse a partir de ella para construir un vector de características completo. Estas métricas pueden incluir parámetros como la energía, la varianza, la entropía o características derivadas de la Transformada de Hilbert-Huang (que se aplica a cada IMF para obtener la amplitud y frecuencia instantáneas) [6](#) [18](#). Por ejemplo, la energía de cada IMF (E_i) puede ser normalizada para obtener una distribución de energía, y la entropía de esta distribución ($H = -\sum (p_i \cdot \log_2(p_i))$, donde $p_i = E_i / E_{total}$) puede servir como una medida de la complejidad o regularidad de la señal cardíaca [6](#). Este tipo de características ha demostrado ser extremadamente útil en la clasificación de EEG, y la metodología es directamente transferible a ECG [18](#).

La aplicación de estas características basadas en IMFs para la clasificación de arritmias ha arrojado resultados notablemente altos. Un estudio de Abdalla et al. utilizó el full ensemble empirical mode decomposition with adaptive noise (CEEMDAN) para extraer parámetros de cuatro IMFs de señales ECG del MIT-BIH database y construyó un vector de características para alimentar una red neuronal artificial. Este enfoque alcanzó una impresionante precisión del 99.9% en la clasificación de arritmias ³². Otro enfoque se centró en la variabilidad de la frecuencia cardíaca (HRV), una medida clave de la función del sistema nervioso autónomo. Al aplicar EEMD a segmentos de 2 minutos de HRV, los investigadores pudieron extraer cinco parámetros de entropía (Rényi, Fuzzy, Dispersion, etc.) a partir de los primeros cuatro IMFs, que contienen la mayoría de la energía de la señal ⁵. Los resultados mostraron que parámetros como la Entropía Fuzzy (FuEn1) y la Entropía de Permutación Multiescala Mejorada (IMPE2) eran los mejores discriminadores entre registros normales y aquellos asociados con muerte súbita cardíaca (SCD), logrando áreas bajo la curva (AUC) de hasta 0.862 y valores de p estadísticamente significativos, confirmando su utilidad para evaluar la disfunción del sistema nervioso autónomo ⁵. Estos estudios demuestran que los IMFs no son meros artefactos de la descomposición, sino que contienen información fisiológica valiosa y codificada de manera significativa.

Además de la clasificación, el EMD ha demostrado ser una herramienta versátil para la identificación biométrica a partir de ECG. Dado que la morfología de la señal ECG es única para cada individuo, se puede utilizar para la autenticación. Un estudio que empleó EMD para la identificación biométrica encontró que los IMFs 1 a 4 eran los más informativos, ya que contenían más del 90% de la energía de la señal en la banda de 1-50 Hz ⁷. Al calcular las densidades espectrales de potencia de estos IMFs y fusionar las características, los investigadores lograron una precisión de identificación del 98.1% en un conjunto de datos que incluía sujetos de diferentes bases de datos ⁷. En el campo de la detección de arritmias, la precisión de los métodos EMD ha sido consistentemente alta. Un algoritmo que combinaba filtros convencionales con EMD para la detección de complejos QRS alcanzó un 95.58% de precisión en el dataset MIT-BIH ³². Como se mencionó anteriormente, los métodos basados en CEEMDAN para la detección de QRS han alcanzado tasas de error de solo 0.13% ⁹. Sin embargo, es crucial tener en cuenta los desafíos prácticos. La detección de picos R puede fallar en presencia de latidos provocados por marcapasos, que aparecen como picos de alta amplitud y corta duración que pueden ser mal interpretados como picos R fisiológicos, lo que podría llevar a diagnósticos erróneos de arritmia ⁴². Por lo tanto, los sistemas EMD deben ser capaces de distinguir entre latidos normales y latidos provocados para ser robustos

en entornos clínicos reales. En conjunto, estas aplicaciones demuestran que el EMD no es solo una técnica de preprocesamiento, sino un motor de análisis profundo que permite una extracción de características más rica y fiable, impulsando el desarrollo de sistemas de diagnóstico automatizado cada vez más precisos.

Herramientas y Librerías de Python para la Implementación de EMD

El ecosistema de software de Python ofrece un conjunto diverso y maduro de herramientas para implementar el Empirical Mode Decomposition y sus variantes, lo que facilita enormemente la investigación y la aplicación práctica en el análisis de señales ECG. La elección de la librería adecuada depende de la necesidad específica del usuario, ya sea la facilidad de uso, el control granular sobre los parámetros del algoritmo o la integración dentro de un flujo de trabajo de procesamiento de biosignales más amplio. Entre las opciones disponibles, destaca PyEMD como una de las librerías más completas y robustas, y la más citada en la literatura académica [29](#) [38](#). PyEMD ofrece implementaciones maduras y estables de EMD, EEMD y CEEMDAN, lo que la convierte en la opción preferida para investigaciones rigurosas que requieren los beneficios de las variantes más avanzadas para mitigar el modo mezclado [38](#). Además, PyEMD se distingue por su flexibilidad, permitiendo al usuario elegir diferentes métodos de interpolación de envolventes (como splines cúbicos naturales, Akima o Hermite) y varios criterios de parada para el proceso de tamizado (como el criterio de Cauchy o el número de iteraciones consecutivas) [38](#). También incorpora soporte para compilación Just-In-Time (JIT) con Numba, lo que puede acelerar significativamente las ejecuciones de largas señales [38](#). La instalación es sencilla a través de pip o conda, y la interfaz de usuario es directa, permitiendo realizar descomposiciones con unas pocas líneas de código [29](#).

Otra librería popular y muy accesible es NeuroKit2, que se enfoca en proporcionar una experiencia de usuario fluida y una integración perfecta dentro de un pipeline de procesamiento de biosignales end-to-end [31](#) [37](#). NeuroKit2 encapsula el EMD en una función de alto nivel llamada `signal_decompose()`, que se puede invocar con `method='emd'` [\[\[31\]\]](#). Esta abstracción simplifica enormemente el proceso para los usuarios que no necesitan un control fino sobre los detalles del algoritmo. Lo que realmente diferencia a NeuroKit2 es su ecología ecológica: una vez que se ha

realizado la descomposición, los IMFs se devuelven como columnas en un DataFrame de pandas, listos para ser utilizados en el resto de las funcionalidades de la biblioteca. Por ejemplo, se puede recomponer una señal a partir de un subconjunto de IMFs usando `signal_recompose()` para eliminar ruido, o los IMFs pueden alimentar directamente a algoritmos de detección de picos (`ecg_peaks`) o delineación de ondas (`ecg_delineate`) [31](#) [37](#). Esta integración nativa hace de NeuroKit2 una herramienta excelente para proyectos que requieren un flujo de trabajo completo, desde la limpieza de la señal hasta la extracción de características y la interpretación fisiológica. Es compatible con altas tasas de muestreo y proporciona funciones para la simulación de señales ECG, lo que facilita el desarrollo y la validación de nuevos algoritmos [31](#).

Para los usuarios que buscan una solución moderna y unificada que integre múltiples métodos de descomposición de señales, PySDKit emerge como una opción prometedora. Publicada en abril de 2024, esta librería ofrece una API similar a la de scikit-learn para EMD, junto con implementaciones de Empirical Wavelet Transform (EWT) y Variational Mode Decomposition (VMD) [34](#). Su diseño modular y su dependencia mínima (NumPy y SciPy) lo hacen ligero y fácil de instalar. PySDKit permite realizar una descomposición EMD de manera concisa, por ejemplo, `EMD().fit_transform(signal, max_imf=3)`, y proporciona herramientas de visualización integradas para examinar los resultados [34](#). Representa una tendencia hacia bibliotecas que agrupan diferentes tecnologías de descomposición, permitiendo a los usuarios comparar y combinar métodos de forma sencilla. Finalmente, para aquellos que necesitan máxima flexibilidad y control sobre cada paso del proceso de tamizado, existe la librería 'emd', que ofrece una interfaz de bajo nivel [35](#). Esta librería permite acceder a funciones granulares como `get_padded_extrema()` para la detección de picos, `interp_envelope()` para la interpolación de envolventes y `sift()` para ejecutar el proceso de tamizado completo, ofreciendo una oportunidad para experimentar personalizadas con el algoritmo [35](#).

A continuación se presenta un ejemplo de código conceptual que demuestra cómo utilizar NeuroKit2 para aplicar EMD a una señal ECG y mejorar la detección de picos R, siguiendo la lógica descrita en las fuentes [31](#) [37](#) [40](#).

```
## Nota: Este es un código conceptual basado en la lógica descrita en las  
## Requiere instalar: pip install neurokit2 wfdb matplotlib numpy
```

```
import numpy as np
```

```

import matplotlib.pyplot as plt
import neurokit2 as nk
import wfdb

## Paso 1: Cargar un ejemplo de señal de ECG (del MIT-BIH Arrhythmia Database)
## Descargamos la base de datos si no está presente
wfdb.dl_database('mitdb')
## Leemos un registro de ejemplo (record_100)
record = wfdb.rdrecord('path/to/mit-bih/arrhythmiaadb/100')
ecg_signal = record.p_signal[:, 0] # Usamos la primera columna (MLII)
sampling_rate = record.fs

## Paso 2: Realizar la descomposición Empirical Mode Decomposition (EMD)
## La función devuelve un DataFrame con los IMFs como columnas
components = nk.signal_decompose(ecg_signal, method='emd')

## Paso 3: Estrategia de Reconstrucción para Mejorar los Picos R
## Inspirado en el método de ref-40
## Sumamos los IMFs de alta frecuencia (IMF1 a IMF4) para capturar detalle
high_freq_imfs = components.iloc[:, 1:5].sum(axis=1) # Suma de IMF1 a IMF4
## Multiplicamos por el producto de los IMFs de baja frecuencia (IMF1 a IMF4)
## Esto realza la prominencia de los picos mientras atenúa el fondo.
low_freq_product = np.prod(components.iloc[:, 1:4], axis=1) # Producto de IMF1 a IMF4
reconstructed_signal_for_peaks = high_freq_imfs*low_freq_product

## Creamos una señal de alta calidad enfocada en los picos R.
reconstructed_signal_for_peaks = high_freq_imfs*low_freq_product

## Paso 4: Detectar los picos R en la señal reconstruida para mejorar la detección
## NeuroKit2 maneja automáticamente el índice de muestreo
_, rpeaks = nk.ecg_peaks(reconstructed_signal_for_peaks, sampling_rate=sampling_rate)

## Paso 5: Visualización comparativa
## Graficamos la señal original y la señal reconstruida con los picos detectados
nk.plot([ecg_signal[:5000], reconstructed_signal_for_peaks[:5000]], labels=['Original ECG', 'Reconstructed ECG for Peaks'])
plt.title("Comparación de la Señal ECG y la Reconstrucción para Detección de Picos R")
plt.show()

## Paso 6: Mostrar los picos R detectados en la señal original
info = nk.ecg_process(ecg_signal, sampling_rate=sampling_rate)

```

```
nk.ecg_plot(info["ECG_Clean"], rpeaks=rpeaks)
plt.title("Detección de Picos R en la Señal ECG Limpia")
plt.show()
```

Este ejemplo ilustra el poder del EMD no solo como un filtro, sino como una herramienta de manipulación de señales que habilita una reconstrucción inteligente para un propósito posterior específico, como la detección de picos, mejorando así la fiabilidad del análisis subsiguiente.

Síntesis Analítica: Fortalezas, Debilidades y Perspectivas Futuras

En conclusión, el Empirical Mode Decomposition ha consolidado su posición como una herramienta fundamental y poderosa en el arsenal del analista de señales biomédicas, especialmente para el análisis de la actividad cardíaca. Su principal fortaleza radica en su capacidad para descomponer señales no lineales y no estacionarias en un conjunto de componentes adaptativos y localizados en el tiempo-frecuencia, los IMFs [8](#) [12](#). A diferencia de las transformadas tradicionales que operan bajo supuestos restrictivos, el EMD se adapta a la propia estructura de la señal, lo que le permite capturar dinámicas complejas como las que se encuentran en el ECG [11](#) [19](#). Esta adaptabilidad se manifiesta de manera más evidente en sus múltiples aplicaciones prácticas. En el ámbito del preprocesamiento, el EMD y sus variantes, como CEEMDAN, ofrecen una vía robusta para la supresión de ruido, incluyendo interferencia de línea de potencia, artefactos musculares y baseline wander, a menudo superando a los filtros convencionales cuando los espectros de señal y ruido se solapan [27](#) [49](#) [50](#). Más allá de la limpieza de la señal, el EMD actúa como un separador de fuentes intrínseco, permitiendo aislar componentes fisiológicos específicos (como el complejo QRS o la onda P) que residen en diferentes bandas de frecuencia-tiempo [9](#) [40](#). Esta capacidad ha impulsado el desarrollo de algoritmos de detección de arritmias con precisiones excepcionales, superando el 99% en algunos casos, y ha facilitado la extracción de características diagnósticas novedosas, como la identificación biométrica a partir de ECG y la evaluación de la disfunción del sistema nervioso autónomo a través de medidas de entropía de los IMFs [5](#) [7](#) [32](#).

Sin embargo, un análisis exhaustivo debe reconocer las debilidades inherentes del método. La limitación más crítica del EMD original es el modo mezclado, un artefacto que dificulta la interpretación de los resultados [16](#) [22](#). Aunque las variantes EEMD y, en particular, CEEMDAN han mitigado este problema de manera considerable, no lo han eliminado por completo, y sigue siendo un factor a considerar en señales con fluctuaciones de energía extremadamente rápidas [3](#) [9](#). Los efectos de borde también pueden introducir distorsiones en los extremos de la señal, requiriendo técnicas de pre-procesamiento adicionales como el padding para su mitigación [16](#) [36](#). Además, el EMD es computacionalmente costoso, lo que lo hace más adecuado para análisis offline en lugar de aplicaciones en tiempo real en dispositivos portátiles [27](#). Desde una perspectiva teórica, la falta de una base matemática rigurosa, como la ortogonalidad de los IMFs, significa que sus resultados deben validarse empíricamente en lugar de depender de principios teóricos universales [36](#). Finalmente, la asignación de componentes fisiológicos a IMFs específicos sigue siendo en gran medida heurística y depende del análisis visual experto, lo que puede introducir un elemento de subjetividad en el proceso de interpretación [23](#).

Mirando hacia el futuro, el panorama de la descomposición de señales es dinámico. Si bien el EMD y sus variantes seguirán siendo una herramienta indispensable, existen métodos alternativos que abordan algunas de sus limitaciones de forma diferente. La Variational Mode Decomposition (VMD), por ejemplo, formula la descomposición como un problema de optimización variacional en el dominio de la frecuencia, lo que resulta en modos estrechos de banda y sin solapamiento, evitando así el modo mezclado de forma inherente y a menudo logrando un mejor SNR que los métodos de EMD familiares [22](#). La elección entre EMD y VMD a menudo dependerá del caso de uso específico, el tipo de señal y la disponibilidad de recursos computacionales. En resumen, el Empirical Mode Decomposition representa un hito en el procesamiento de señales adaptativas. Su filosofía de extracción de bases de datos ha abierto nuevas vías para el análisis de ECG, permitiendo una comprensión más profunda de la actividad cardíaca y la creación de herramientas de diagnóstico automatizado cada vez más sofisticadas. Para el investigador o el ingeniero biomédico, dominar el EMD y sus variantes es esencial para navegar con éxito el complejo paisaje de las señales biológicas.

Referencia

1. Arrhythmia ECG Noise Reduction by Ensemble Empirical ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC3247747/>
2. An effective electrocardiogram segments denoising method ... <https://ietresearch.onlinelibrary.wiley.com/doi/10.1049/sil2.12232>
3. Electrocardiogram Analysis by Means of Empirical Mode ... <https://www.mdpi.com/2076-3417/13/6/3569>
4. Deep attention model for arrhythmia signal classification ... <https://www.nature.com/articles/s41598-025-89752-0>
5. Early Detection of Sudden Cardiac Death by Using ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC7052183/>
6. AN EMD AND IMF ENERGY ENTROPY-BASED ... <https://www.worldscientific.com/doi/full/10.1142/S0219519423400638?srsId=AfmBOooURqiXRwxSAdT6d7F6BptX8nFjCgGqaLKIHKs7Z2xyk7FkDqT>
7. A Human ECG Identification System Based on Ensemble ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC3690084/>
8. Empirical mode decomposition based ECG enhancement ... <https://www.sciencedirect.com/science/article/abs/pii/S0010482511002083>
9. An Accurate QRS complex and P wave Detection in ECG ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC7970665/>
10. ECG signal feature extraction trends in methods and ... <https://link.springer.com/article/10.1186/s12938-023-01075-1>
11. (PDF) Extraction of Features from ECG Signal https://www.researchgate.net/publication/351148889_Extraction_of_Features_from_ECG_Signal
12. A survey on Hilbert-Huang transform: Evolution, challenges ... <https://www.sciencedirect.com/science/article/abs/pii/S1051200421003316>
13. A review on Hilbert – Huang transform: Method and its ... <https://agupubs.onlinelibrary.wiley.com/doi/10.1029/2007RG000228>
14. The Hilbert-Huang Transform: Letting the Data Speak for ... https://medium.com/@zeneil_writes/the-hilbert-huang-transform-letting-the-data-speak-for-itself-5c72561ee63a

15. The Hilbert–Huang Transform: A High Resolution Spectral ... <https://pubs.geoscienceworld.org/ssa/srl/article/84/6/1074/349062/The-Hilbert-Huang-Transform-A-High-Resolution>
16. Hilbert–Huang transform https://en.wikipedia.org/wiki/Hilbert%E2%80%93Huang_transform
17. Empirical Mode Decomposition: The Most Intuitive Way to ... <https://towardsdatascience.com/preprocessing-signal-data-with-empirical-mode-decomposition/>
18. The Empirical Mode Decomposition for handling non- ... <https://blogs.sas.com/content/subconsciousmusings/2023/05/16/empirical-mode-decomposition-non-stationary-time-series/>
19. Why use EMD? - Empirical Mode Decomposition in Python https://emd.readthedocs.io/en/stable/emd_tutorials/00_quick_start/emd_tutorial_00_start_02_whyemd.html
20. Decomposing Signal Using Empirical Mode Decomposition <https://medium.com/data-science/decomposing-signal-using-empirical-mode-decomposition-algorithm-explanation-for-dummy-93a93304c541>
21. Comparison of Empirical Mode Decomposition, Wavelets ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC8710482/>
22. Comparison of advanced signal decomposition techniques ... <https://www.nature.com/articles/s41598-025-22128-6>
23. Empirical Wavelet Transform & its Comparison with ... <https://www.ijert.org/empirical-wavelet-transform-its-comparison-with-empirical-mode-decomposition-a-review>
24. empirical mode decomposition - an overview <https://www.sciencedirect.com/topics/computer-science/empirical-mode-decomposition>
25. An Adaptive ECG Noise Removal Process Based on ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC9402333/>
26. Denoising of Electrocardiogram (ECG) signal by using ... <https://www.sciencedirect.com/science/article/abs/pii/S0208521617303017>
27. Comparative evaluation of filtration techniques for ECG ... <https://www.nature.com/articles/s41598-025-26476-1>
28. Isolation of multiple electrocardiogram artifacts using ... <https://peerj.com/articles/cs-1189/>
29. Intro — PyEMD 0.4.0 documentation <https://pyemd.readthedocs.io/en/latest/intro.html>
30. empirical-mode-decomposition <https://github.com/topics/empirical-mode-decomposition?o=asc&s=updated>

31. **neurokit2** <https://pypi.org/project/neurokit2/>
32. **LDCNN: A new arrhythmia detection technique with ECG ...** <https://pmc.ncbi.nlm.nih.gov/articles/PMC11366442/>
33. **Ten quick tips for electrocardiogram (ECG) signal processing** <https://peerj.com/articles/cs-2295/>
34. **PySDKit: signal decomposition in Python** <https://medium.com/@wwhenxuan/pysdkit-signal-decomposition-in-python-275706283e93>
35. **Intro to the sift — emd 0.0.1.dev239 documentation** https://emd.readthedocs.io/en/stable/emd_tutorials/01_sifting/emd_tutorial_01_sift_01_siftintro.html
36. **Sifting Process - an overview** <https://www.sciencedirect.com/topics/computer-science/sifting-process>
37. **neuropsychology/NeuroKit: NeuroKit2: The Python Toolbox ...** <https://github.com/neuropsychology/NeuroKit>
38. **laszukdawid/PyEMD: Python implementation of Empirical ...** <https://github.com/laszukdawid/PyEMD>
39. **dav0dea/goofi-pipe: real-time neuro-/biosignal processing ...** <https://github.com/PhilippThaelke/goofi-pipe>
40. **A New Method of Identifying Characteristic Points in the ...** <https://pmc.ncbi.nlm.nih.gov/articles/PMC9861967/>
41. **A Human ECG Identification System Based on Ensemble ...** <https://www.mdpi.com/1424-8220/13/5/6832>
42. **Help Needed with R-Peak Detection Accuracy in ECG ...** https://www.reddit.com/r/DSP/comments/1ek988a/help_needed_with_rpeak_detection_accuracy_in_ecg/
43. **A hybrid variational mode decomposition framework for ...** <https://pmc.ncbi.nlm.nih.gov/articles/PMC12267840/>
44. **ECG R peak detection in Python: a comparison of libraries** <https://samproell.io/posts/signal/ecg-library-comparison/>
45. **py-ecg-detectors** <https://pypi.org/project/py-ecg-detectors/>
46. **Working with ECG Data in Python - In Digits** https://www.indigits.com/post/2022/10/ecg_python/
47. **Popular ECG R peak detectors written in python** <https://zenodo.org/records/7652725>
48. **How to filter ECG and detect R peaks** <https://dsp.stackexchange.com/questions/58155/how-to-filter-ecg-and-detect-r-peaks>
49. **A hybrid method for removal of power line interference and ...** <https://www.sciencedirect.com/science/article/abs/pii/S174680942100063X>

50. Review of noise removal techniques in ECG signals - Chatterjee <https://ietresearch.onlinelibrary.wiley.com/doi/10.1049/iet-spr.2020.0104>
51. Preprocessing and Denoising Techniques for ... <https://www.mdpi.com/2306-5354/11/11/1109>
52. Advanced Time-Frequency Methods for ECG Waves ... <https://www.mdpi.com/2075-4418/13/2/308>
53. Pre-Processing techniques and artificial intelligence ... <https://www.sciencedirect.com/science/article/pii/S0010482523013732>
54. Electrocardiogram analysis for cardiac arrhythmia ... <https://www.nature.com/articles/s41598-025-93906-5>
55. A Systematic Review of ECG Arrhythmia Classification <https://arxiv.org/html/2503.07276v1>
56. Unraveling Arrhythmias with Graph-Based Analysis <https://www.mdpi.com/2079-3197/12/2/21>
57. The impact of the MIT-BIH arrhythmia database https://www.researchgate.net/publication/11895647_The_impact_of_the_MIT-BIH_arrhythmia_database
58. Sequential algorithm for life threatening cardiac pathologies ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC2944264/>
59. Exploiting correlation of ECG with certain EMD functions for ... <https://www.sciencedirect.com/science/article/abs/pii/S0010482510001745>
60. Arrhythmia ECG Noise Reduction by Ensemble Empirical ... <https://www.mdpi.com/1424-8220/10/6/6063>
61. EMD IMF Entropy Optimized Feature Extraction & Classification https://www.worldscientific.com/doi/full/10.1142/S0219519423400638?srsId=AfmBOoqeKfFsEOsWQTPYwfSO_S8ey4IBWnufsrVrNsP5ezDmj1EfuZiT
62. Empirical mode decomposition in clinical signal analysis <https://dl.acm.org/doi/abs/10.1016/j.compbimed.2025.110566>
63. A two-step pre-processing tool to remove Gaussian and ... <https://pmc.ncbi.nlm.nih.gov/articles/PMC9626590/>